

WSI - Przeszukiwanie przestrzeni

Piotr Kozłowski

14 marca 2026

1 Opis zadania

Zadanie polega na implementacji algorytmu gradientu prostego oraz zbadaniu jego zachowania dla różnych wartości parametru kroku i punktów początkowych. Metodę należy zastosować dla następujących funkcji:

- suma kwadratów:

$$f(x) = x_1^2 + x_2^2$$

- funkcja Matyasa:

$$f(x) = 0.26(x_1^2 + x_2^2) - 0.48x_1x_2$$

gdzie x_i należy do przedziału $[-10, 10]$, dla każdego $i = 1, 2$.

2 Dobór warunków stopu algorytmu

Zdecydowano się na następujące warunki stopu:

- maksymalna liczba iteracji `MAX_ITER` = 1000,
- próg tolerancji normy gradientu `EPSILON` = 10^{-6}


Maksymalna liczba iteracji pełni rolę zabezpieczenia przed nadmiernie długim działaniem algorytmu w przypadku braku zbieżności.

Z kolei przyjęty próg tolerancji normy gradientu jest na tyle mały, aby uzyskane rozwiązanie można było uznać za dostatecznie dokładne przy jednoczesnym zachowaniu rozsądnego czasu obliczeń.

3 Badanie wpływu hiperparametrów

3.1 Wpływ kroku uczenia

3.1.1 Suma kwadratów




Rysunek 1: Wykresy par wartości funkcji $x_1^2 + x_2^2$ i numeru iteracji dla wybranych wartości kroku uczenia.

Krok uczenia	0,0001	0,01	0,1	0,25	0,49	0,5	0,501	0,75	1
Liczba iteracji	1000	834	76	25	5	1	3	25	1000
Znalezione minimum x_1	6,56	3,86e-07	3,46e-07	2,39e-07	2,56e-08	0,00	-6,41e-08	-2,39e-07	8,01
Znalezione minimum x_2	-5,26	-3,10e-07	-2,77e-07	-1,92e-07	-2,06e-08	0,00	5,14e-08	-1,92e-07	-6,43
Średni błąd kwadratowy	35,37	1,22e-13	9,82e-14	4,69e-14	5,40e-16	0,00	3,38e-15	4,69e-14	52,77

Tabela 1: Wpływ kroku uczenia na zbieżność metody gradientu prostego dla funkcji $x_1^2 + x_2^2$. Pogrubiono kolumnę z optymalnym krokiem pod względem liczby iteracji i błędu średniokwadratowego.

3.1.2 Funkcja Matyasa




Rysunek 2: Wykresy par wartości funkcji Matyasa i numeru iteracji dla wybranych wartości kroku uczenia.

Krok uczenia	0,01	0,1	1	1,5	1,89	1,9	1,91	1,98	1,99
Liczba iteracji	1000	1000	311	206	162	161	164	743	1000
Znalezione minimum x_1	3,83	0,10	1,75e-05	1,66e-05	1,69e-05	1,69e-05	1,29e-05	-6,93e-07	9,89e-05
Znalezione minimum x_2	3,83	0,10	1,75e-05	1,67e-05	1,68e-05	1,71e-05	1,21e-05	6,93e-07	-9,89e-05
Średni błąd kwadratowy	14,71	0,01	3,07e-10	2,78e-10	2,84e-10	2,89e-10	1,56e-10	4,81e-13	9,78e-09

Tabela 2: Wpływ kroku uczenia na zbieżność metody gradientu prostego dla funkcji Matyasa. Pogrubiono kolumnę z optymalnym krokiem pod względem liczby iteracji przy akceptowalnym błędzie.

3.2 Wpływ punktu początkowego

3.2.1 Suma kwadratów




Rysunek 3: Wykresy par wartości funkcji $x_1^2 + x_2^2$ i numeru iteracji dla trzech wybranych punktów początkowych.

Punkt początkowy $[x_1^0; x_2^0]$	$[8,012; 6,43]$	$[-9; 1]$	$[2,034; 1,054]$
Liczba iteracji	1	1	1
Znalezione minimum $[x_1; x_2]$	$[0,00; 0,00]$	$[0,00; 0,00]$	$[0,00; 0,00]$
Średni błąd kwadratowy	0,00	0,00	0,00

Tabela 3: Wpływ punktu początkowego na zbieżność metody gradientu prostego dla sumy kwadratów

3.2.2 Funkcja Matyasa



Rysunek 4: Wykresy par wartości funkcji Matyasa i numeru iteracji dla trzech wybranych punktów początkowych.

Punkt początkowy $[x_1^0; x_2^0]$	[8,012; 6,43]	[-9; 7]	[2,034; 1,054]
Liczba iteracji	164	155	145
Znalezione minimum $[x_1; x_2]$	[1,70e-05; 1,69e-05]	[-4,13e-06; -5,42e-06]	[1,61e-05; 1,64e-05]
Średni błąd kwadratowy	2,87e-10	2,32e-11	2,64e-10

Tabela 4: Wpływ punktu początkowego na zbieżność metody gradientu prostego dla funkcji Matyasa

4 Wnioski końcowe

4.1 Wybór kroku uczenia

Po przebadaniu zachowania algorytmu dla dziewięciu wybranych wartości kroku uczenia stwierdzono podobną zależność w przypadku obu badanych funkcji celu i sformułowano następujące wnioski:

- Każda funkcja celu posiada optymalną wartość kroku uczenia, przy której liczba iteracji i błąd średniokwadratowy są minimalne. Dla funkcji sumy kwadratów optymalny krok wynosi 0,5, natomiast dla funkcji Matyasa krok równy 1,9 minimalizuje liczbę iteracji przy akceptowalnym błędzie.
- Zbyt mały krok uczenia znacząco wydłuża proces optymalizacji, uniemożliwiając osiągnięcie optimum w ramach określonej liczby iteracji. Natomiast zbyt duży krok może prowadzić do oscylacji wokół minimum, co zwiększa zarówno liczbę iteracji, jak i końcowy błąd. Dla bardzo dużych kroków metoda może się stać nawet niestabilna.
- Dla funkcji bardziej złożonych, takich jak funkcja Matyasa, może istnieć kilka wartości kroku uznawanych za optymalne w zależności od przyjętego kryterium (szybkość vs. dokładność). W praktyce warto dobrać krok kompromisowy, który zapewnia przyspieszenie algorytmu przy zachowaniu akceptowalnej dokładności.
- Dobór odpowiedniego kroku uczenia jest kluczowy dla efektywności metody gradientu prostego i powinien uwzględniać zarówno charakterystykę funkcji celu, jak i wymagania dotyczące szybkości oraz dokładności optymalizacji.


4.2 Wybór punktu początkowego

Dla obu funkcji celu wybrano optymalną wartość kroku uczenia i przetestowano działanie metody gradientu prostego dla trzech różnych punktów początkowych. Na podstawie uzyskanych wyników można sformułować następujące wnioski:

- Dla funkcji o prostym kształcie i jednoznacznym minimum globalnym, takiej jak suma kwadratów, wybór punktu początkowego ma niewielki wpływ na ostateczny wynik algorytmu.
- W przypadku bardziej złożonych funkcji, takich jak funkcja Matyasa, punkt początkowy istotnie wpływa zarówno na osiągnięte minimum, jak i na szybkość zbiegania algorytmu.
- Odległość punktu początkowego od globalnego minimum wpływa na liczbę iteracji potrzebnych do znalezienia optimum - im bliżej minimum znajduje się punkt startowy, tym szybciej metoda gradientu prostego dochodzi do celu.

5 Porównanie metod GD i SGD


Podobnie do metody gradientu prostego zaimplementowano metodę SGD polegającą na dodaniu stochastycznego szumu do gradientu. Następnie porównano działanie obu algorytmów dla tych samych punktów początkowych i wartości kroku uczenia.



Rysunek 5: Porównanie metody gradientu prostego i SGD dla sumy kwadratów.

	Liczba iteracji	Błąd średniokwadratowy
GD	1	0,00
SGD	1000	1,09e-06

Tabela 5: Porównanie metody gradientu prostego i SGD dla sumy kwadratów.



Rysunek 6: Porównanie metody gradientu prostego i SGD dla funkcji Matyasa.

	Liczba iteracji	Błąd średniokwadratowy
GD	157	2,04e-10
SGD	1000	7,15e-06

Tabela 6: Porównanie metody gradientu prostego i SGD dla funkcji Matyasa.

5.1 Wnioski

- W przypadku obu badanych funkcji celu algorytm SGD znacząco wolniej zbiega do minimum w porównaniu z metodą gradientu prostego. Wynika to z faktu, że w SGD do gradientu dodawany jest składnik losowy, który powoduje większą zmienność kolejnych kroków optymalizacji. W efekcie trajektoria iteracji nie jest tak stabilna jak w przypadku GD, co wydłuża proces dochodzenia do minimum.
- Metoda gradientu prostego w analizowanych przykładach osiąga bardzo mały błąd średniokwadratowy przy znacznie mniejszej liczbie iteracji, ponieważ wykorzystuje dokładny gradient funkcji celu, dzięki czemu kolejne kroki są bardziej precyzyjnie skierowane w stronę minimum.
- Trajektoria optymalizacji w SGD jest bardziej nieregularna i oscyluje w pobliżu minimum. Powoduje to, że nawet po dużej liczbie iteracji błąd może być większy niż w przypadku GD.
- Zaletą SGD jest jednak obecność losowości, która może umożliwiać opuszczanie minimów lokalnych. W bardziej złożonych problemach optymalizacyjnych może to prowadzić do znalezienia lepszych rozwiązań globalnych niż w przypadku deterministycznej metody GD.